

1) Si tenemos un alto error de entrenamiento y de test. ¿Sirve de algo añadir más muestras?

Si ya se tiene un bajo error de entrenamiento y de prueba, es probable que aumentar el número de muestras no aporte mucho a mejorar el rendimiento del modelo. El modelo ya está siendo capaz de generalizar bien a partir de las muestras de entrenamiento, por lo que añadir más muestras podría no aportar información adicional relevante. Sin embargo, siempre es recomendable validar el modelo con más datos para confirmar su rendimiento.

2) Si tenemos un alto error de entrenamiento y de test. ¿Sirve de algo añadir más variables predictoras?

Añadir más variables predictoras puede empeorar el sobreajuste si no aportan información relevante, lo que resulta en un peor rendimiento del modelo. Es crucial realizar un análisis de la relevancia de las variables actuales y potenciales, considerar técnicas de selección de características y regularización para evitar el sobreajuste.

3) Si tenemos un alto error de test, pero bajo de entrenamiento. ¿Sirve de algo añadir más muestras?

Añadir más muestras de entrenamiento puede ayudar a mejorar el rendimiento del modelo si el bajo error de entrenamiento indica un posible sobreajuste. Esto puede ayudar a generalizar mejor el modelo y a reducir el sobreajuste.

Es importante evaluar si la adición de más muestras mejora la generalización del modelo y aporta información relevante para la tarea de predicción.

4) ¿Hay que normalizar las entradas para knn? 5) ¿Hay que normalizar las salidas cuando es knn para regresión?

Para KNN, es recomendable normalizar las entradas para que las distancias sean comparables.

En el caso de la regresión con KNN, no es necesario normalizar las salidas, ya que KNN no realiza ninguna suposición sobre la distribución de las salidas.

6) ¿Cómo procedemos si al llegar a una intersección de un árbol, falta el valor de la variable divisora?

Cuando falta el valor de la variable divisoria en un árbol de decisión, se puede recurrir a diferentes estrategias, como asignar el valor más común.

7) ¿Qué relación hay entre el "mínimo número de ejemplos" y el sobreaprendizaje en un árbol?

El "mínimo número de ejemplos" en un árbol de decisión está relacionado con el sobreajuste. Un valor bajo puede conducir a un sobreajuste, mientras que un valor alto puede llevar a un sobreaprendizaje. En general, un valor equilibrado ayuda a prevenir el sobreajuste y a mejorar la capacidad de generalización del modelo.

8) Una estructura como la del ej 1 de neuronas. Decir como quedaría Z2 (sería z1 si

consideras la salida de la capa de entrada a_0) dejando indicadas las operaciones con matrices sin resolverlas.

9) Lo mismo, pero ahora a_3 .

10) Da los a_2 y el error de la neurona de salida. Lo mismo que en los anteriores para el error de la capa 2.

11) Diferencia entre full connected y local connected en la estructura de una neurona.

En una red neuronal, una capa completamente conectada (fully connected) implica que cada neurona en una capa está conectada a todas las neuronas de la capa anterior o posterior. Por otro lado, una capa localmente conectada (locally connected) utiliza solo las salidas de la capa anterior que están en "la vecindad" de la neurona, lo que reduce el número de parámetros y la complejidad del modelo.

13) Dada una lista de observaciones con coeficientes (alfas), y un valor de c , decir cuáles de ellos están en el margen.

Todos los que tienen α mayor que cero.

14) Al aumentar " c " en svc, ¿tendemos al sobre aprendizaje o al subaprendizaje?

El aumento de " c " en SVM tiende al sobreaprendizaje.

15) ¿Qué relación hay entre el número de vectores de soporte y " c "?

A medida que el valor de " C " en las Máquinas de Vectores de Soporte (SVM) aumenta, el número de vectores de soporte disminuye. Un valor mayor de " C " conduce a un margen más estrecho y a menos vectores de soporte, lo que resulta en un clasificador con menor sesgo pero mayor varianza.

16) ¿Cómo afecta γ al kernel radial?

El parámetro γ en el kernel radial de las Máquinas de Vectores de Soporte (SVM) controla la influencia de un solo ejemplo de entrenamiento, donde un valor bajo significa una influencia alta y un valor alto significa una influencia baja. En resumen, un valor bajo de γ da como resultado un modelo con un ajuste más suave, mientras que un valor alto puede llevar a un ajuste excesivo (sobreajuste).

17) ¿Qué es el α -sub- m en ada boosting?

El " α -sub- m " en AdaBoost representa el peso asignado a un clasificador débil en cada etapa del proceso de boosting. Este peso se utiliza para actualizar la importancia de las observaciones, dándole más peso a las observaciones que fueron clasificadas incorrectamente por los clasificadores anteriores, lo que permite que los clasificadores posteriores se enfoquen en los casos más difíciles de clasificar.

18)¿Como afecta alfa-sub-m a lo que contribuye el árbol m a la salida?

No afecta realmente el alfa sub m es una medida de error

19)¿Qué relación hay en random forest entre m y una baja calidad de los predictores?

En Random Forest, un valor bajo de "m" (número de predictores considerados en cada división) puede estar relacionado con una baja calidad de los predictores, lo que puede afectar la capacidad del modelo para capturar la información relevante, lo que lleva a una disminución en la precisión predictiva

20)¿Qué relación hay en random forest entre m y el sobre aprendizaje?

El parámetro "m" en Random Forest controla la cantidad de predictores considerados en cada división de árbol. Un valor bajo de "m" puede aumentar el sobreajuste, especialmente en presencia de predictores de baja calidad, ya que los árboles pueden llegar a depender en exceso de un subconjunto reducido de predictores, lo que lleva a una menor diversidad en los árboles y, por lo tanto, a un mayor sobreajuste